

# 講義の概要

## 多変量解析 - 第 I 講

村田 昇

## 講義について

### 講義の概要

- 講義題目：多変量解析
- 担当：村田 昇
- 授業の目標
  - 統計解析手法である **多変量解析** の基本的な解析法に習熟する
    - \* 大規模データから効果的に情報を抽出
    - \* データの背後に潜む統計的構造を分析
  - 解析法の数理科学的側面を理解する
  - 実データに多変量解析を適用する

### 多変量解析とは

複数の変量からなるデータを分析する手法の総称

- **回帰分析**：複数の変数から注目する変数の値を説明
- **主成分分析**：全体を説明する少数の特徴量を構成
- **判別分析**：特徴量の違いでカテゴリ分けを実行
- **クラスタ分析**：特徴量の違いに着目してクラスタ (データのグループ) を構成
- **時系列解析**：時間とともに変化する現象を記述

### 受講にあたっての注意

- 微分積分学と線形代数学を復習しておく
- 自身で解析するための計算機環境を準備する
- 講義の資料は Moodle および Web で公開する
- 成績評価は課題の提出 (2 回) による
  - 回帰分析
  - 自由課題

## 講義計画 (予定)

- オリエンテーション
- 数学的準備 (1 回)
- 回帰分析 (3 回)
- 第 1 回レポート (回帰分析終了から 2 週間で締切)
- 主成分分析 (2 回)
- 判別分析 (2 回)
- クラスタ分析 (2 回)
- 時系列解析入門 (2 回)
- 第 2 回レポート (1 月末締切, 自由課題)

## 多変量解析

### 多変量解析とは

- 複数の変量からなるデータを分析する手法の総称
  - 回帰分析: 複数の量を用いて注目する変数の値を説明する
  - 主成分分析: 全体を説明する少数の特徴量を構成する
  - 判別分析: 特徴量の違いでカテゴリ分けを行う
  - クラスタ分析: 特徴量の違いに着目してクラスタを構成する
  - 時系列解析: 時間とともに変化する現象を記述する

### 回帰分析の考え方

- ある変数を別の変数によって説明・予測するための関係式を構成する
  - 単回帰: 一つの変数で目的変数を説明する
  - 重回帰: 複数の変数で目的変数を説明する
- 分析の事例
  - 身長から体重を予測する式を作り, ある身長の人がある体重だったときに, それが普通かどうか判定する
  - 築年数・駅からの距離・広さ・間取りで家賃を説明する式を作り, 新規に家賃を設定する際に利用する

### 単回帰の例

### 重回帰の例

### 主成分分析の考え方

- 多数の変数が与えられたときに, 変数のもつ構造を効率的に記述できる少数個の特徴量を構成する
- 分析の事例
  - 野球選手の打撃成績 (打率, 本塁打数, 打点など) から, 打者としての特徴を記述する指標を作成する
  - 複数銘柄からなる株価の時系列データから, 市場全体の変動を記述する総合指標を作成する

表 1: 体重と脳の重さ

species	body [kg]	brain [g]
Mountain beaver	1.350	8.1
Cow	465.000	423.0
Grey wolf	36.330	119.5
Goat	27.660	115.0
Guinea pig	1.040	5.5
Dipliodocus	11700.000	50.0
Asian elephant	2547.000	4603.0
Donkey	187.100	419.0
...	..	..




図 1: 体重と脳の重さの関係

表 2: ワインの価格と生産環境

年号	価格 (対数)	冬の降雨	気温	秋の降雨	経過年
1952	-0.99868	600	17.1167	160	31
1953	-0.4544	690	16.7333	80	30
1954	NA	430	15.3833	180	29
1955	-0.80796	502	17.15	130	28
1956	NA	440	15.65	140	27
1957	-1.50926	420	16.1333	110	26
1958	-1.71655	582	16.4167	187	25
1959	-0.418	485	17.4833	187	24
...	..	..	..	..	..




図 2: 体重と脳の重さの関係 (両対数)




図 3: 体重と脳の重さの関係 (単回帰)




図 4: ワインの価格と生産環境の関係




図 5: 生産環境によるワイン価格の予測 (重回帰)

表 3: 県別の生活環境 (一部)

	昼夜人口比	年少人口比	老年人口比	人口増減率
北海道	100.0	11.7	26.0	-0.47
青森県	100.0	12.1	27.0	-0.95
岩手県	99.7	12.4	27.9	-0.84
宮城県	100.2	13.0	22.9	-0.09
秋田県	99.9	11.1	30.7	-1.12
山形県	99.8	12.6	28.3	-0.78
福島県	99.6	12.9	26.1	-1.41
茨城県	97.2	13.2	23.8	-0.51
...	..	..	..	..

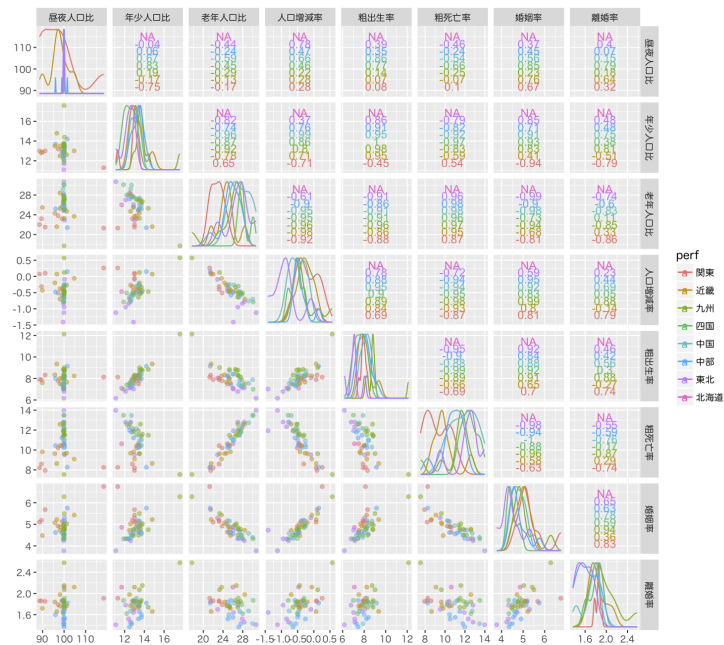


図 6: 県別の生活環境 (人口動態) の散布図

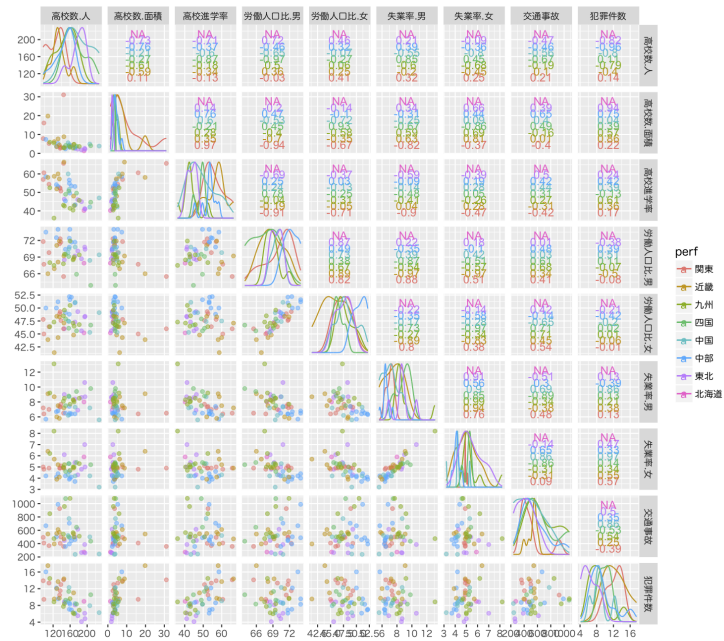


図 7: 県別の生活環境 (教育・労働) の散布図




図 8: 県別の生活環境 (貯蓄・余暇) の散布図





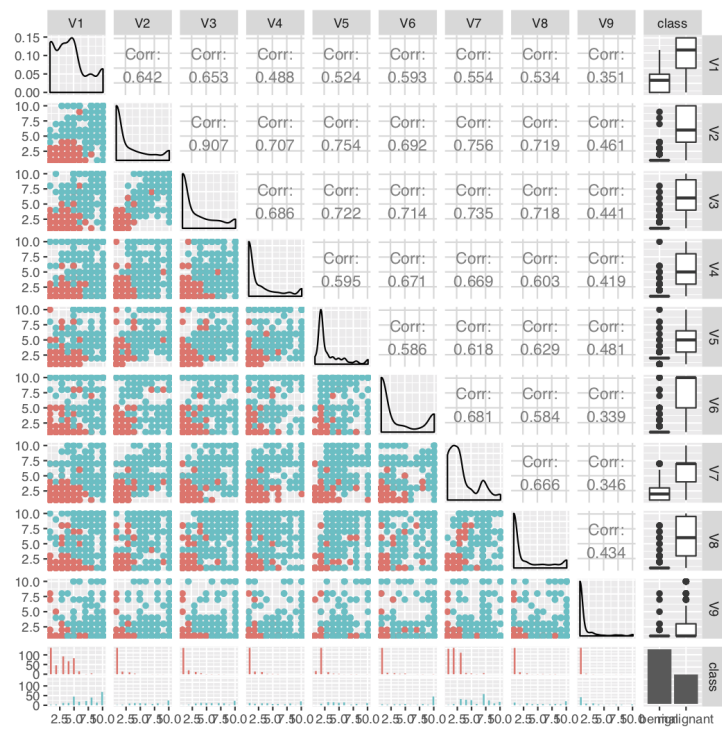


図 10: 乳癌患者 (良性・悪性) の生研検査の散布図




図 11: 生研検査の主成分分析




図 12: 生研検査による乳癌患者の判別分析

- 階層的な方法: 系統樹を作成する
- 非階層的な方法: グループの代表値を推定する
- 分析の事例
  - 映画に関するアンケート調査から潜在的なジャンル(グループ)を抽出する
  - 顧客の購買履歴から、嗜好の異なる顧客グループに分類し、グループごとの販売戦略を立てる

## クラスタ分析の例

表 5: おむすびの具に関するアンケート

	梅	鮭	昆布	鰹	明太	鱈子	ツナ	他
北海道	13.86	27.94	5.58	5.26	9.26	15.06	11.61	11.39
青森	14.93	30.79	7.01	2.43	10.36	11.58	11.58	11.28
岩手	17.91	23.13	5.22	3.35	17.91	10.07	10.44	11.94
宮城	15.16	29.5	10	1.66	14.83	8.83	12.83	7.16
秋田	10.63	31.38	5.31	3.19	14.89	13.29	10.63	10.63
山形	16.58	20.27	8.29	1.38	18.89	10.13	12.9	11.52
福島	12.37	21.99	8.93	3.43	16.49	9.62	19.24	7.9
茨城	15.42	26.49	7.98	2.54	18.33	11.79	11.79	5.62
...	..	..	..	..	..	..	..	..

## 時系列解析の考え方

- 時間とともに変化する現象を記述するために、未来の値を過去の値で近似する式を構成する
  - 自己回帰 (AR モデル): 過去の影響の記述
  - 移動平均 (MA モデル): 記憶のある不確定性

Favorite Omusubi (2009)




図 13: おむすびの具に関するアンケート分析 (県別の集計)

Dendrogram of Omusubi Data




図 14: アンケート結果にもとづく県のクラスタ分析

- 分析の事例

- 市町村の過去の年齢別の人口変動から将来の人口比率を予測する
- 食品・飲料の季節ごとの販売履歴から将来の需要量を予測する

## 時系列解析の例

表 6: 航空機旅客量の変遷

	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	...
1949	112	118	132	129	121	135	148	148	136	..
1950	115	126	141	135	125	149	170	170	158	..
1951	145	150	178	163	172	178	199	199	184	..
1952	171	180	193	181	183	218	230	242	209	..
1953	196	196	236	235	229	243	264	272	237	..
1954	204	188	235	227	234	264	302	293	259	..
1955	242	233	267	269	270	315	364	347	312	..
...	..	..	..	..	..	..	..	..	..	..




図 15: 航空機旅客量の変遷

## 次週の予定

- 数学的準備
- 確率
  - 確率分布
  - 確率密度関数・確率質量関数
  - 正規分布 ( $\chi^2$  分布,  $t$  分布,  $F$  分布)
  - 最尤法 (尤度関数)




図 16: 階差時系列の自己相関分析




図 17: 航空機旅客量の予測 (SARIMA モデルによる)

- 統計量 (標本平均, 不偏分散・共分散, 相関係数)
  - ベイズの定理
- 関数の微分
  - ベクトルによる微分
  - 行列による微分