

回帰分析

回帰モデルの考え方と推定

村田 昇

講義の内容

- 第1回：回帰モデルの考え方と推定
- 第2回：モデルの評価
- 第3回：モデルによる予測と発展的なモデル

回帰分析の考え方

回帰分析

- ある変量を別の変量で説明する関係式を構成する
- 関係式：回帰式 (regression equation)
 - 説明される側：目的変数, 被説明変数, 従属変数, 応答変数
 - 説明する側：説明変数, 独立変数, 共変量
- 説明変数の数による分類
 - 一つの場合：単回帰 (simple regression)
 - 複数の場合：重回帰 (multiple regression)

一般の回帰の枠組

- 説明変数： $x_1, \dots, x_p$ (p 次元)
- 目的変数： y (1 次元)
- 回帰式： y を $x_1, \dots, x_p$ で説明するための関係式

$$y = f(x_1, \dots, x_p)$$

- 観測データ：n 個の $(y, x_1, \dots, x_p)$ の組

$$\{(y_i, x_{i1}, \dots, x_{ip})\}_{i=1}^n$$

線形回帰

- 任意の f では一般的すぎて分析に不向き
- f として **1 次関数** を考える ある定数 $\beta_0, \beta_1, \dots, \beta_p$ を用いた式：

$$f(x_1, \dots, x_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

- 1 次関数の場合：**線形回帰** (linear regression)
- 一般の場合：**非線形回帰** (nonlinear regression)
- 非線形関係は新たな説明変数の導入で対応可能
 - 適切な多項式： $x_j^2, x_j x_k, x_j x_k x_l, \dots$
 - その他の非線形変換： $\log x_j, x_j^\alpha, \dots$
 - 全ての非線形関係ではないことに注意

回帰係数

- 線形回帰式

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

- $\beta_0, \beta_1, \dots, \beta_p$ ：**回帰係数** (regression coefficients)
- β_0 ：**定数項 / 切片** (constant term / intersection)
- 線形回帰分析 (linear regression analysis)
 - 未知の回帰係数をデータから決定する分析方法
 - 決定された回帰係数の統計的な性質を診断

回帰の確率モデル

- 回帰式の不確定性
 - データは一般に観測誤差などランダムな変動を含む
 - 回帰式がそのまま成立することは期待できない

- 確率モデル：データのばらつきを表す項 ϵ_i を追加

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \epsilon_i \quad (i = 1, \dots, n)$$

– $\epsilon_1, \dots, \epsilon_n$: 誤差項 / 攪乱項 (error / disturbance term)

* 誤差項は独立な確率変数と仮定

* 多くの場合, 平均 0, 分散 σ^2 の正規分布を仮定

- 推定 (estimation) : 観測データから回帰係数を決定

回帰係数の推定

残差

- 残差 (residual) : 回帰式で説明できない変動
- 回帰係数 $\beta = (\beta_0, \beta_1, \dots, \beta_p)^\top$ を持つ回帰式の残差

$$e_i(\beta) = y_i - (\beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}) \quad (i = 1, \dots, n)$$

- 残差 $e_i(\beta)$ の絶対値が小さいほど当てはまりがよい

最小二乗法

- 残差平方和 (residual sum of squares)

$$S(\beta) = \sum_{i=1}^n e_i(\beta)^2$$

- 最小二乗推定量 (least squares estimator) : $S(\beta)$ を最小にする β

$$\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p)^\top = \arg \min_{\beta} S(\beta)$$

行列の定義

- デザイン行列 (design matrix)

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

– $n \times (p+1)$ 行列

ベクトルの定義

- 目的変数, 誤差, 回帰係数のベクトル

$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

- y, ϵ は n 次元ベクトル
- β は $p+1$ 次元ベクトル

行列・ベクトルによる表現

- 確率モデル

$$y = X\beta + \epsilon$$

- 残差平方和

$$S(\beta) = (y - X\beta)^T (y - X\beta)$$

解の条件

- 解 β では残差平方和の勾配は零ベクトル

$$\frac{\partial S}{\partial \beta}(\beta) = \left(\frac{\partial S}{\partial \beta_0}(\beta), \frac{\partial S}{\partial \beta_1}(\beta), \dots, \frac{\partial S}{\partial \beta_p}(\beta) \right)^T = 0$$

演習

問題

- 残差平方和 $S(\beta)$ をベクトル β で微分して解の条件を求めなさい

正規方程式

正規方程式

正規方程式 (normal equation)

$$X^T X \beta = X^T y$$

- $X^T X$: **Gram 行列** (Gram matrix)
 - $(p+1) \times (p+1)$ 行列 (正方行列)
 - 半正定値行列 (固有値が非負)

正規方程式の解

- 正規方程式の基本的な性質
 - 正規方程式は必ず解をもつ (一意に決まらない場合もある)
 - 正規方程式の解は最小二乗推定量であるための必要条件
- 解の一意性の条件
 - Gram 行列 $X^T X$ が **正則**
 - X の列ベクトルが独立 (後述)

正規方程式の解

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

最小二乗推定量の性質

解析の上での良い条件

- 最小二乗推定量がただ一つだけ存在する条件

- $X^T X$ が正則
- $X^T X$ の階数が $p+1$
- X の階数が $p+1$
- X の列ベクトルが 1 次独立
- これらは同値条件

解析の上での良くない条件

- 説明変数が 1 次従属：多重共線性 (multicollinearity)
- 多重共線性が強くないように説明変数を選択
 - X の列 (説明変数) の独立性を担保する
 - 説明変数が互いに異なる情報をもつように選ぶ
 - 似た性質をもつ説明変数の重複は避ける

推定の幾何学的解釈

- あてはめ値 / 予測値 (fitted values / predicted values)

$$\hat{y} = X\hat{\beta} = \hat{\beta}_0 X_{0(\text{切片})} + \cdots + \hat{\beta}_p X_{p(\text{第 } p \text{ 成分})}$$




Figure 1: $n = 3$, $p + 1 = 2$ の場合の最小二乗法による推定

- 最小二乗推定量 $\hat{y}$ の幾何学的性質
 - $L[X]$: X の列ベクトルが張る $\mathbb{R}^n$ の線形部分空間
 - X の階数が $p+1$ ならば $L[X]$ の次元は $p+1$ (解の一意性)

- $\hat{y}$ は y の $L[X]$ への直交射影
- 残差 (residuals) $\hat{\epsilon} = y - \hat{y}$ はあてはめ値 $\hat{y}$ に直交

$$\hat{\epsilon} \cdot \hat{y} = 0$$

線形回帰式と標本平均

- $x_i = (x_{i1}, \dots, x_{ip})^T$: i 番目の観測データの説明変数
- 説明変数および目的変数の標本平均

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$

- $\hat{\beta}$ が最小二乗推定量のとき以下が成立

$$\bar{y} = (1, \bar{x}^T) \hat{\beta}$$

演習

問題

- 最小二乗推定量について以下を示しなさい
 - 残差の標本平均が 0 となる
 - 目的変数や残差のベクトルについて以下を示せばよい

$$1^T (y - \hat{y}) = 1^T \hat{\epsilon} = 0$$

ただし $1 = (1, \dots, 1)^T$ とする

- 回帰式が標本平均を通る

$$\bar{y} = (1, \bar{x}^T) \hat{\beta}$$

残差の分解

最小二乗推定量の残差

- 観測値と推定値 $\hat{\beta}$ による予測値の差

$$\hat{\epsilon}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \cdots + \hat{\beta}_p x_{ip}) \quad (i = 1, \dots, n)$$

- 誤差項 $\epsilon_1, \dots, \epsilon_n$ の推定値
- 全てができるだけ小さいほど良い
- 予測値とは独立に偏りが無いほど良い

- 残差ベクトル

$$\hat{\epsilon} = y - \hat{y} = (\hat{\epsilon}_1, \hat{\epsilon}_2, \dots, \hat{\epsilon}_n)^T$$

平方和の分解

- $\bar{y} = \bar{y}1 = (\bar{y}, \bar{y}, \dots, \bar{y})^T$: 標本平均のベクトル
- いろいろなばらつき
 - $S_y = (y - \bar{y})^T (y - \bar{y})$: 目的変数のばらつき
 - $S = (y - \hat{y})^T (y - \hat{y})$: 残差のばらつき ($\hat{\epsilon}^T \hat{\epsilon}$)
 - $S_r = (\hat{y} - \bar{y})^T (\hat{y} - \bar{y})$: あてはめ値 (回帰) のばらつき
- 3つのばらつき (平方和) の関係

$$(y - \bar{y})^T (y - \bar{y}) = (y - \hat{y})^T (y - \hat{y}) + (\hat{y} - \bar{y})^T (\hat{y} - \bar{y})$$

$$S_y = S + S_r$$

演習

問題

- 以下の関係式を示しなさい
 - あてはめ値と残差のベクトルが直交する

$$\hat{y}^T (y - \hat{y}) = \hat{y}^T \hat{\epsilon} = 0$$

- 残差平方和の分解が成り立つ

$$S_y = S + S_r$$

決定係数

回帰式の寄与

- ばらつきの分解

$$S_y \text{ (目的変数)} = S \text{ (残差)} + S_r \text{ (あてはめ値)}$$

- 回帰式で説明できるばらつきの比率

$$\text{(回帰式の寄与率)} = \frac{S_r}{S_y} = 1 - \frac{S}{S_y}$$

- 回帰式のあてはまり具合を評価する代表的な指標

決定係数 (R^2 値)

決定係数 (R-squared)

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

自由度調整済み決定係数 (adjusted R-squared)

$$\bar{R}^2 = 1 - \frac{\frac{1}{n-p-1} \sum_{i=1}^n \hat{\epsilon}_i^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

- 不偏分散で補正している

解析の事例

実データによる例

- 気象庁より取得した東京の気候データ
 - 気象庁 <https://www.data.jma.go.jp/gmd/risk/obsdl/index.php>
 - データ https://noboru-murata.github.io/multivariate-analysis/data/tokyo_weather.csv
- 気温に影響を与える要因を分析

データの概要

モデルの検討

気温を説明する 5 種類の線形回帰モデル

モデル 1 : 気温 = F(気圧)

モデル 2 : 気温 = F(日射)

モデル 3 : 気温 = F(気圧, 日射)


モデル 4 : 気温 = F(気圧, 日射, 湿度)

モデル 5 : 気温 = F(気圧, 日射, 雲量)


Table 1: 東京の8月の気候データ

日付	気温	降雨	日射	降雪	風向	風速	気圧	湿度	雲量
2025-08-01	26.4	6.0	9.16	0	N	3.3	999.0	83	10.0
2025-08-02	28.9	20.5	20.34	0	SSE	3.7	996.5	84	9.5
2025-08-03	30.4	0.0	21.10	0	SSE	2.6	1000.1	77	8.5
2025-08-04	31.3	0.0	26.14	0	S	4.3	1002.5	66	3.3
2025-08-05	32.1	0.0	25.58	0	SSE	3.2	1001.6	67	4.5
2025-08-06	32.3	0.0	23.20	0	SSE	2.4	999.8	68	7.5
2025-08-07	29.5	0.0	12.16	0	N	2.1	995.4	76	8.8
2025-08-08	28.6	3.0	17.46	0	NW	2.6	998.7	71	5.5
2025-08-09	28.4	0.0	18.21	0	SSE	2.7	1004.0	70	8.0
2025-08-10	26.3	25.5	4.32	0	S	4.1	1002.8	90	10.0
2025-08-11	27.1	11.5	7.97	0	S	5.6	1003.8	90	9.8
2025-08-12	28.2	1.0	6.88	0	SSW	4.4	1007.7	83	10.0
2025-08-13	27.9	0.0	17.21	0	E	2.4	1013.5	76	9.3
2025-08-14	27.8	0.0	20.39	0	S	2.6	1014.2	71	8.3
2025-08-15	28.7	0.0	24.42	0	S	2.9	1011.2	73	5.0
2025-08-16	28.8	1.0	19.08	0	S	3.1	1011.1	80	8.0
2025-08-17	29.8	0.0	22.79	0	SSE	3.2	1010.4	77	6.3
2025-08-18	31.0	0.0	22.43	0	SSE	2.5	1011.5	68	7.8
2025-08-19	29.9	0.0	22.92	0	SE	2.8	1009.6	76	2.0
2025-08-20	30.4	0.0	23.70	0	SSE	2.7	1007.5	72	3.5
2025-08-21	31.3	0.0	23.14	0	SSE	2.5	1007.4	63	6.5
2025-08-22	30.3	0.0	15.55	0	SSE	2.2	1007.9	71	10.0
2025-08-23	30.4	0.0	21.77	0	SSE	2.6	1007.7	73	7.3
2025-08-24	31.3	0.0	23.05	0	NE	2.3	1008.9	70	3.8
2025-08-25	30.6	0.0	17.21	0	SSE	2.7	1010.9	71	8.5
2025-08-26	30.1	0.0	20.41	0	SSE	3.7	1009.1	75	3.0
2025-08-27	30.7	0.0	23.07	0	S	3.6	1006.1	67	3.8
2025-08-28	28.9	0.0	15.70	0	SSE	3.0	1011.0	63	6.8
2025-08-29	28.7	0.0	18.41	0	SSE	2.4	1012.1	76	6.5
2025-08-30	31.6	0.0	23.26	0	S	2.5	1010.5	67	4.0
2025-08-31	30.9	0.0	21.83	0	SE	2.7	1010.3	73	1.3


関連するデータの散布図



モデル1の推定結果



モデル 2 の推定結果



モデル 3 の推定結果





Table 2: 決定係数によるモデルの比較

変数	モデル 1		モデル 2		モデル 3		モデル 4		モデル 5	
	係数	標準誤差	係数	標準誤差	係数	標準誤差	係数	標準誤差	係数	標準誤差
気圧	0.01	0.057			-0.04	0.037	-0.05	0.035	-0.05	0.038
日射			0.22	0.034	0.22	0.034	0.15	0.043	0.21	0.047
湿度							-0.09	0.035		
雲量									-0.06	0.102
R ²	0.002		0.585		0.604		0.678		0.609	
Adjusted R ²	-0.032		0.571		0.576		0.642		0.566	

Abbreviations: CI = Confidence Interval, SE = Standard Error

観測値とあてはめ値の比較



決定係数によるモデルの比較

次回の予定

- 第1回：回帰モデルの考え方と推定
- 第2回：モデルの評価
- 第3回：モデルによる予測と発展的なモデル