

# 回帰分析

## 回帰モデルの考え方と推定

村田 昇

## 講義の内容

- 第 1 回 : 回帰モデルの考え方と推定
- 第 2 回 : モデルの評価
- 第 3 回 : モデルによる予測と発展的なモデル

## 回帰分析の考え方

### 回帰分析

- ある変量を別の変量で説明する関係式を構成する
- 関係式 : **回帰式** (regression equation)
  - 説明される側 : **目的変数**, 被説明変数, 従属変数, 応答変数
  - 説明する側 : **説明変数**, 独立変数, 共変量
- 説明変数の数による分類
  - 一つの場合 : **単回帰** (simple regression)
  - 複数の場合 : **重回帰** (multiple regression)

### 一般の回帰の枠組

- **説明変数** :  $x_1, \dots, x_p$  (p 次元)
- **目的変数** :  $y$  (1 次元)
- **回帰式** :  $y$  を  $x_1, \dots, x_p$  で説明するための関係式

$$y = f(x_1, \dots, x_p)$$

- 観測データ : n 個の  $(y, x_1, \dots, x_p)$  の組

$$\{(y_i, x_{i1}, \dots, x_{ip})\}_{i=1}^n$$

## 線形回帰

- 任意の  $f$  では一般的すぎて分析に不向き
- $f$  として **1 次関数** を考える  
ある定数  $\beta_0, \beta_1, \dots, \beta_p$  を用いた式：
$$f(x_1, \dots, x_p) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$
  - 1 次関数の場合：**線形回帰** (linear regression)
  - 一般の場合：非線形回帰 (nonlinear regression)
- 非線形関係は新たな説明変数の導入で対応可能
  - 適切な多項式： $x_j^2, x_j x_k, x_j x_k x_l, \dots$
  - その他の非線形変換： $\log x_j, x_j^\alpha, \dots$
  - 全ての非線形関係ではないことに注意

## 回帰係数

- 線形回帰式
$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$
  - $\beta_0, \beta_1, \dots, \beta_p$ ：**回帰係数** (regression coefficients)
  - $\beta_0$ ：**定数項 / 切片** (constant term / intersection)
- 線形回帰分析 (linear regression analysis)
  - 未知の回帰係数をデータから決定する分析方法
  - 決定された回帰係数の統計的な性質を診断

## 回帰の確率モデル

- 回帰式の不確定性
  - データは一般に観測誤差などランダムな変動を含む
  - 回帰式がそのまま成立することは期待できない
- 確率モデル：データのばらつきを表す項  $\epsilon_i$  を追加

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \epsilon_i \quad (i = 1, \dots, n)$$

- $\epsilon_1, \dots, \epsilon_n$ ：**誤差項 / 攪乱項** (error / disturbance term)
  - \* 誤差項は独立な確率変数と仮定
  - \* 多くの場合、平均 0、分散  $\sigma^2$  の正規分布を仮定
- **推定** (estimation)：観測データから回帰係数を決定

## 回帰係数の推定

### 残差

- **残差** (residual)：回帰式で説明できない変動
- 回帰係数  $\beta = (\beta_0, \beta_1, \dots, \beta_p)^T$  を持つ回帰式の残差

$$e_i(\beta) = y_i - (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) \quad (i = 1, \dots, n)$$

- 残差  $e_i(\beta)$  の絶対値が小さいほど当てはまりがよい

## 最小二乗法

- 残差平方和 (residual sum of squares)

$$S(\boldsymbol{\beta}) = \sum_{i=1}^n e_i(\boldsymbol{\beta})^2$$

- 最小二乗推定量 (least squares estimator)

残差平方和  $S(\boldsymbol{\beta})$  を最小にする  $\boldsymbol{\beta}$

$$\hat{\boldsymbol{\beta}} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p)^\top = \arg \min_{\boldsymbol{\beta}} S(\boldsymbol{\beta})$$

## 行列の定義

- デザイン行列 (design matrix)

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

–  $n \times (p+1)$  行列

## ベクトルの定義

- 目的変数, 誤差, 回帰係数のベクトル

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad \boldsymbol{\epsilon} = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

–  $\mathbf{y}, \boldsymbol{\epsilon}$  は  $n$  次元ベクトル

–  $\boldsymbol{\beta}$  は  $p+1$  次元ベクトル

## 行列・ベクトルによる表現

- 確率モデル

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

- 残差平方和

$$S(\boldsymbol{\beta}) = (\mathbf{y} - X\boldsymbol{\beta})^\top (\mathbf{y} - X\boldsymbol{\beta})$$

## 解の条件

- 解  $\boldsymbol{\beta}$  では残差平方和の勾配は零ベクトル

$$\frac{\partial S}{\partial \boldsymbol{\beta}}(\boldsymbol{\beta}) = \left( \frac{\partial S}{\partial \beta_0}(\boldsymbol{\beta}), \frac{\partial S}{\partial \beta_1}(\boldsymbol{\beta}), \dots, \frac{\partial S}{\partial \beta_p}(\boldsymbol{\beta}) \right)^\top = \mathbf{0}$$

## 演習

### 問題

- 残差平方和  $S(\boldsymbol{\beta})$  をベクトル  $\boldsymbol{\beta}$  で微分して解の条件を求めなさい

### 解答例

- 残差平方和を展開しておく

$$\begin{aligned} S(\boldsymbol{\beta}) &= (\mathbf{y} - X\boldsymbol{\beta})^\top (\mathbf{y} - X\boldsymbol{\beta}) \\ &= \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top X\boldsymbol{\beta} - (X\boldsymbol{\beta})^\top \mathbf{y} + (X\boldsymbol{\beta})^\top X\boldsymbol{\beta} \\ &= \mathbf{y}^\top \mathbf{y} - \mathbf{y}^\top X\boldsymbol{\beta} - \boldsymbol{\beta}^\top X^\top \mathbf{y} + \boldsymbol{\beta}^\top X^\top X\boldsymbol{\beta} \end{aligned}$$

- ベクトルによる微分を行うと以下ようになる

$$\begin{aligned} \frac{\partial S}{\partial \boldsymbol{\beta}}(\boldsymbol{\beta}) &= -(\mathbf{y}^\top X)^\top - X^\top \mathbf{y} + (X^\top X + (X^\top X)^\top)\boldsymbol{\beta} \\ &= -2X^\top \mathbf{y} + 2X^\top X\boldsymbol{\beta} \end{aligned}$$

- したがって  $\boldsymbol{\beta}$  の満たす条件は以下となる

$$\begin{aligned} -2X^\top \mathbf{y} + 2X^\top X\boldsymbol{\beta} &= 0 \quad \text{より} \\ X^\top X\boldsymbol{\beta} &= X^\top \mathbf{y} \end{aligned}$$

### 補足

- 成分ごとの計算は以下ようになる

$$\frac{\partial S}{\partial \beta_j}(\boldsymbol{\beta}) = -2 \sum_{i=1}^n \left( y_i - \sum_{k=0}^p \beta_k x_{ik} \right) x_{ij} = 0$$

ただし,  $x_{i0} = 1$  ( $i = 1, \dots, n$ ),  $j = 0, 1, \dots, p$

$$\sum_{i=1}^n x_{ij} \left( \sum_{k=0}^p x_{ik} \beta_k \right) = \sum_{i=1}^n x_{ij} y_i \quad (j = 0, 1, \dots, p)$$

$x_{ij}$  は行列  $X$  の  $(i, j)$  成分であることに注意

## 正規方程式

### 正規方程式

- 正規方程式 (normal equation)

$$X^\top X\boldsymbol{\beta} = X^\top \mathbf{y}$$

- $X^\top X$  : **Gram 行列** (Gram matrix)
  - $(p+1) \times (p+1)$  行列 (正方行列)
  - 正定対称行列 (固有値が非負)

## 正規方程式の解

- 正規方程式の基本的な性質
  - 正規方程式は必ず解をもつ (一意に決まらない場合もある)
  - 正規方程式の解は最小二乗推定量であるための必要条件
- 解の一意性の条件
  - Gram 行列  $X^T X$  が **正則**
  - $X$  の列ベクトルが独立 (後述)
- 正規方程式の解

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

## 最小二乗推定量の性質

### 解析の上での良い条件

- 最小二乗推定量がただ一つだけ存在する条件
  - $X^T X$  が正則
  - $X^T X$  の階数が  $p+1$
  - $X$  の階数が  $p+1$
  - $X$  の列ベクトルが **1 次独立**

これらは同値条件

### 解析の上での良くない条件

- 説明変数が 1 次従属: **多重共線性** (multicollinearity)
- 多重共線性が強くないように説明変数を選択
  - $X$  の列 (説明変数) の独立性を担保する
  - 説明変数が互いに異なる情報をもつように選ぶ
  - 似た性質をもつ説明変数の重複は避ける

## 推定の幾何学的解釈

- **あてはめ値 / 予測値** (fitted values / predicted values)

$$\hat{y} = X\hat{\beta} = \hat{\beta}_0 X_{\text{第 0 列}} + \cdots + \hat{\beta}_p X_{\text{第 p 列}}$$

- 最小二乗推定量  $\hat{y}$  の幾何学的性質
  - $L[X]$ :  $X$  の列ベクトルが張る  $\mathbb{R}^n$  の線形部分空間
  - $X$  の階数が  $p+1$  ならば  $L[X]$  の次元は  $p+1$  (解の一意性)
  - $\hat{y}$  は  $y$  の  $L[X]$  への直交射影
  - **残差** (residuals)  $\hat{\epsilon} = y - \hat{y}$  はあてはめ値  $\hat{y}$  に直交

$$\hat{\epsilon} \cdot \hat{y} = 0$$




図 1:  $n = 3, p + 1 = 2$  の場合の最小二乗法による推定

## 線形回帰式と標本平均

- $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ :  $i$  番目の観測データの説明変数
- 説明変数および目的変数の標本平均

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$

- $\hat{\boldsymbol{\beta}}$  が最小二乗推定量のとき以下が成立

$$\bar{y} = (1, \bar{\mathbf{x}}^\top) \hat{\boldsymbol{\beta}}$$

## 演習

### 問題

- 最小二乗推定量について以下を示しなさい
    - 残差の標本平均が 0 となる
- 目的変数や残差のベクトルについて以下を示せばよい

$$\mathbf{1}^\top (\mathbf{y} - \hat{\mathbf{y}}) = \mathbf{1}^\top \hat{\boldsymbol{\epsilon}} = 0$$

ただし  $\mathbf{1} = (1, \dots, 1)^\top$  とする

- 回帰式が標本平均を通る

$$\bar{y} = (1, \bar{\mathbf{x}}^\top) \hat{\boldsymbol{\beta}}$$

### 解答例

- 残差の表現を整理する

$$\begin{aligned} \hat{\boldsymbol{\epsilon}} &= \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X} \hat{\boldsymbol{\beta}} \\ &= \mathbf{y} - \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y} \end{aligned}$$

- 左から  $\mathbf{X}^\top$  を乗じる

$$X^T \mathbf{y} - X^T X (X^T X)^{-1} X^T \mathbf{y} = X^T \mathbf{y} - X^T \mathbf{y} = 0$$

- 行列  $X$  の 1 列目が  $\mathbf{1}$  であることより明らか
- 説明変数の標本平均をデザイン行列で表す

$$\mathbf{1}^T X = n(1, \bar{\mathbf{x}}^T)$$

- したがって以下が成立する

$$\begin{aligned} n(1, \bar{\mathbf{x}}^T) \hat{\boldsymbol{\beta}} &= \mathbf{1}^T X \hat{\boldsymbol{\beta}} \\ &= \mathbf{1}^T \hat{\mathbf{y}} = \mathbf{1}^T \mathbf{y} \\ &= n\bar{y} \end{aligned}$$

## 残差の分解

### 最小二乗推定量の残差

- 観測値と推定値  $\hat{\boldsymbol{\beta}}$  による予測値の差

$$\hat{\epsilon}_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \cdots + \hat{\beta}_p x_{ip}) \quad (i = 1, \dots, n)$$

- 誤差項  $\epsilon_1, \dots, \epsilon_n$  の推定値
- 全てができるだけ小さいほど良い
- 予測値とは独立に偏りが無いほど良い

- 残差ベクトル

$$\hat{\boldsymbol{\epsilon}} = \mathbf{y} - \hat{\mathbf{y}} = (\hat{\epsilon}_1, \hat{\epsilon}_2, \dots, \hat{\epsilon}_n)^T$$

### 平方和の分解

- $\bar{\mathbf{y}} = \bar{y}\mathbf{1} = (\bar{y}, \bar{y}, \dots, \bar{y})^T$ : 標本平均のベクトル
- いろいろなばらつき
  - $S_y = (\mathbf{y} - \bar{\mathbf{y}})^T (\mathbf{y} - \bar{\mathbf{y}})$ : 目的変数のばらつき
  - $S = (\mathbf{y} - \hat{\mathbf{y}})^T (\mathbf{y} - \hat{\mathbf{y}})$ : 残差のばらつき ( $\hat{\boldsymbol{\epsilon}}^T \hat{\boldsymbol{\epsilon}}$ )
  - $S_r = (\hat{\mathbf{y}} - \bar{\mathbf{y}})^T (\hat{\mathbf{y}} - \bar{\mathbf{y}})$ : あてはめ値 (回帰) のばらつき
- 3 つのばらつき (平方和) の関係

$$(\mathbf{y} - \bar{\mathbf{y}})^T (\mathbf{y} - \bar{\mathbf{y}}) = (\mathbf{y} - \hat{\mathbf{y}})^T (\mathbf{y} - \hat{\mathbf{y}}) + (\hat{\mathbf{y}} - \bar{\mathbf{y}})^T (\hat{\mathbf{y}} - \bar{\mathbf{y}})$$

$$S_y = S + S_r$$

## 演習

### 問題

- 以下の関係式を示しなさい
  - あてはめ値と残差のベクトルが直交する

$$\hat{\mathbf{y}}^T (\mathbf{y} - \hat{\mathbf{y}}) = \hat{\mathbf{y}}^T \hat{\boldsymbol{\epsilon}} = 0$$

- 残差平方和の分解が成り立つ

$$S_y = S + S_r$$

### 解答例

- 残差の表現を整理する

$$\begin{aligned}\hat{\boldsymbol{\epsilon}} &= \mathbf{y} - \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \\ &= (\mathbf{I} - \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T) \mathbf{y}\end{aligned}$$

- 左から  $\hat{\mathbf{y}}$  を乗じる

$$\begin{aligned}\hat{\mathbf{y}}^T \hat{\boldsymbol{\epsilon}} &= \hat{\boldsymbol{\beta}}^T \mathbf{X}^T (\mathbf{I} - \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T) \mathbf{y} \\ &= \hat{\boldsymbol{\beta}}^T (\mathbf{X}^T - \mathbf{X}^T \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T) \mathbf{y} \\ &= \hat{\boldsymbol{\beta}}^T (\mathbf{X}^T - \mathbf{X}^T) \mathbf{y} = 0\end{aligned}$$

- 以下の関係を用いて展開すればよい

$$\mathbf{y} - \bar{\mathbf{y}} = \mathbf{y} - \hat{\mathbf{y}} + \hat{\mathbf{y}} - \bar{\mathbf{y}}$$

$$\text{ただし } \bar{\mathbf{y}} = \bar{y} \mathbf{1}$$

- このとき以下の項は 0 になる

$$(\hat{\mathbf{y}} - \bar{\mathbf{y}})^T (\mathbf{y} - \hat{\mathbf{y}}) = \hat{\mathbf{y}}^T (\mathbf{y} - \hat{\mathbf{y}}) - \bar{y} \mathbf{1}^T (\mathbf{y} - \hat{\mathbf{y}}) = 0$$

## 決定係数

### 回帰式の寄与

- ばらつきの分解

$$S_y \text{ (目的変数)} = S \text{ (残差)} + S_r \text{ (あてはめ値)}$$

- 回帰式で説明できるばらつきの比率

$$(\text{回帰式の寄与率}) = \frac{S_r}{S_y} = 1 - \frac{S}{S_y}$$

- 回帰式のあてはまり具合を評価する代表的な指標



## 決定係数 ( $R^2$ 値)

- 決定係数 (R-squared)

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- 自由度調整済み決定係数 (adjusted R-squared)

$$\bar{R}^2 = 1 - \frac{\frac{1}{n-p-1} \sum_{i=1}^n \hat{\epsilon}_i^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

- 不偏分散で補正している

## 解析の事例

### 実データによる例

- 気象庁より取得した東京の気候データ
  - 気象庁 <https://www.data.jma.go.jp/gmd/risk/obsdl/index.php>
  - データ [https://noboru-murata.github.io/multivariate-analysis/data/tokyo\\_weather.csv](https://noboru-murata.github.io/multivariate-analysis/data/tokyo_weather.csv)

### 東京の8月の気候の分析

- データの一部
- 気温を説明する5種類の線形回帰モデルを検討
  - モデル1: 気温 = F(気圧)
  - モデル2: 気温 = F(日射)
  - モデル3: 気温 = F(気圧, 日射)
  - モデル4: 気温 = F(気圧, 日射, 湿度)
  - モデル5: 気温 = F(気圧, 日射, 雲量)

### 分析の視覚化

- 関連するデータの散布図
- モデル1の推定結果
- モデル2の推定結果
- モデル3の推定結果
- 観測値とあてはめ値の比較

### モデルの比較

- 決定係数 ( $R^2$ , Adjusted  $R^2$ )

表 1: 東京の 8 月の気候

| 日付         | 気温   | 降雨   | 日射    | 降雪 | 風向  | 風速  | 気圧     | 湿度 | 雲量  |
|------------|------|------|-------|----|-----|-----|--------|----|-----|
| 2022-08-01 | 30.6 | 0    | 24.53 | 0  | SSE | 2.8 | 1010.1 | 72 | 8.8 |
| 2022-08-02 | 31.6 | 0    | 24.78 | 0  | SSE | 2.5 | 1008.8 | 71 | 9.8 |
| 2022-08-03 | 31.5 | 0    | 21.24 | 0  | SSE | 2.3 | 1005.1 | 75 | 7.3 |
| 2022-08-04 | 24.6 | 18   | 3.46  | 0  | NE  | 2.7 | 1006   | 89 | 10  |
| 2022-08-05 | 23.8 | 0    | 7.65  | 0  | NE  | 2.9 | 1006.1 | 83 | 9.8 |
| 2022-08-06 | 25.2 | 0    | 17.06 | 0  | SSE | 2.4 | 1008.1 | 73 | 10  |
| 2022-08-07 | 27.6 | 0    | 14.45 | 0  | SSE | 2.2 | 1009.3 | 80 | 8.3 |
| 2022-08-08 | 29.8 | 0    | 22.52 | 0  | S   | 4.5 | 1008.5 | 75 | 4.8 |
| 2022-08-09 | 30.9 | 0    | 25.5  | 0  | S   | 5.5 | 1006.9 | 69 | 6.8 |
| 2022-08-10 | 30.5 | 0    | 25.99 | 0  | S   | 5.3 | 1007.2 | 70 | 6   |
| 2022-08-11 | 29.5 | 0    | 22.9  | 0  | S   | 5.4 | 1007.5 | 75 | 6   |
| 2022-08-12 | 28.3 | 2    | 15.36 | 0  | S   | 5.8 | 1007.5 | 81 | 9.8 |
| 2022-08-13 | 25.5 | 47.5 | 4.53  | 0  | S   | 4.8 | 1005.6 | 94 | 10  |
| 2022-08-14 | 28.2 | 0    | 16.28 | 0  | SSE | 2.6 | 1003   | 84 | 8.8 |
| 2022-08-15 | 29.4 | 0    | 18.65 | 0  | S   | 2.5 | 1003.4 | 78 | 8.8 |
| 2022-08-16 | 31   | 0    | 20.5  | 0  | SSW | 4.8 | 1000.6 | 70 | 8.3 |
| 2022-08-17 | 27.3 | 5    | 8.87  | 0  | NE  | 2.5 | 1005.8 | 77 | 10  |
| 2022-08-18 | 26.8 | 13   | 8.74  | 0  | S   | 2.8 | 1001.7 | 81 | 6   |
| 2022-08-19 | 27.5 | 0    | 23.52 | 0  | SSE | 3.4 | 1001.7 | 62 | 3   |
| 2022-08-20 | 26.4 | 1.5  | 13.5  | 0  | NW  | 1.8 | 1000.6 | 82 | 9.8 |
| 2022-08-21 | 26   | 1    | 8.96  | 0  | NE  | 2.1 | 1002.3 | 87 | 10  |
| 2022-08-22 | 26.2 | 0    | 9.05  | 0  | NNE | 2.5 | 1005.5 | 82 | 10  |
| 2022-08-23 | 28.7 | 0    | 17.94 | 0  | S   | 3.2 | 1003.2 | 83 | 8.3 |
| 2022-08-24 | 27.8 | 2    | 12.86 | 0  | NE  | 2.9 | 1003.2 | 79 | 10  |
| 2022-08-25 | 25.7 | 0    | 9.83  | 0  | SE  | 2   | 1004.1 | 77 | 10  |
| 2022-08-26 | 27   | 3.5  | 10.05 | 0  | SSE | 2.1 | 1002.5 | 89 | 10  |
| 2022-08-27 | 29   | 0    | 19.87 | 0  | SSE | 3.3 | 1002.7 | 80 | 5.5 |
| 2022-08-28 | 23.7 | 5    | 4.58  | 0  | NE  | 3   | 1009.2 | 87 | 9.8 |
| 2022-08-29 | 23.3 | 0.5  | 15.45 | 0  | NE  | 2.8 | 1016.1 | 69 | 8   |
| 2022-08-30 | 22.8 | 5    | 10.12 | 0  | NNE | 1.9 | 1012.5 | 88 | 10  |
| 2022-08-31 | 27.1 | 1    | 17.46 | 0  | S   | 3.2 | 1007.6 | 85 | 8.8 |

表 2: 寄与率によるモデルの比較

|                         | 目的変数              |                |                  |                  |                  |
|-------------------------|-------------------|----------------|------------------|------------------|------------------|
|                         | モデル 1             | モデル 2          | 気温<br>モデル 3      | モデル 4            | モデル 5            |
| 気圧                      | -0.178 (0.127)    |                | -0.223 (0.068)   | -0.214 (0.067)   | -0.242 (0.068)   |
| 日射                      |                   | 0.297 (0.041)  | 0.306 (0.036)    | 0.366 (0.056)    | 0.348 (0.045)    |
| 湿度                      |                   |                |                  | 0.071 (0.051)    |                  |
| 雲量                      |                   |                |                  |                  | 0.238 (0.161)    |
| Constant                | 206.535 (127.430) | 22.969 (0.690) | 247.477 (68.433) | 231.843 (68.254) | 263.717 (67.941) |
| R <sup>2</sup>          | 0.064             | 0.641          | 0.741            | 0.758            | 0.760            |
| Adjusted R <sup>2</sup> | 0.031             | 0.628          | 0.722            | 0.731            | 0.733            |




図 2: 散布図




図 3: モデル 1




図 4: モデル 2




図 5: モデル 3




図 6: モデルの比較

## 次回の予定

- 第 1 回 : 回帰モデルの考え方と推定
- 第 2 回 : モデルの評価
- 第 3 回 : モデルによる予測と発展的なモデル