

# 回帰分析

予測と発展的なモデル

村田 昇

## 講義の内容

- 第1回: 回帰モデルの考え方と推定
- 第2回: モデルの評価
- 第3回: モデルによる予測と発展的なモデル

## 回帰分析の復習

### 線形回帰モデル

- 目的変数 を 説明変数 で説明する関係式を構成
  - 説明変数:  $x_1, \dots, x_p$  (p 次元)
  - 目的変数:  $y$  (1 次元)
- 回帰係数  $\beta_0, \beta_1, \dots, \beta_p$  を用いた一次式

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

- 誤差項 を含む確率モデルで観測データを表現

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \epsilon_i \quad (i = 1, \dots, n)$$

## 問題設定

- 確率モデル

$$y = X\beta + \epsilon, \quad \epsilon \sim \text{確率分布}$$

- 式の評価：残差平方和 の最小化による推定

$$S(\beta) = (y - X\beta)^T(y - X\beta)$$

## 解とその一意性

- 解の条件：正規方程式

$$X^T X \beta = X^T y$$

- 解の一意性：Gram 行列  $X^T X$  が正則

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

## 解析の事例

### 気温に影響を与える要因の分析

- 気象庁より取得した東京の気候データ (再掲)
  - 気象庁 <https://www.data.jma.go.jp/gmd/risk/obsdl/index.php>

### データの概要


### モデルの検討

- 気温を説明する 5 種類の線形回帰モデル
  - モデル 1：気温 = F(気圧)
  - モデル 2：気温 = F(日射)
  - モデル 3：気温 = F(気圧, 日射)
  - モデル 4：気温 = F(気圧, 日射, 湿度)
  - モデル 5：気温 = F(気圧, 日射, 雲量)

Table 1: 東京の8月の気候データ

| 日付         | 気温   | 降雨   | 日射    | 降雪 | 風向  | 風速  | 気圧     | 湿度 | 雲量   |
|------------|------|------|-------|----|-----|-----|--------|----|------|
| 2025-08-01 | 26.4 | 6.0  | 9.16  | 0  | N   | 3.3 | 999.0  | 83 | 10.0 |
| 2025-08-02 | 28.9 | 20.5 | 20.34 | 0  | SSE | 3.7 | 996.5  | 84 | 9.5  |
| 2025-08-03 | 30.4 | 0.0  | 21.10 | 0  | SSE | 2.6 | 1000.1 | 77 | 8.5  |
| 2025-08-04 | 31.3 | 0.0  | 26.14 | 0  | S   | 4.3 | 1002.5 | 66 | 3.3  |
| 2025-08-05 | 32.1 | 0.0  | 25.58 | 0  | SSE | 3.2 | 1001.6 | 67 | 4.5  |
| 2025-08-06 | 32.3 | 0.0  | 23.20 | 0  | SSE | 2.4 | 999.8  | 68 | 7.5  |
| 2025-08-07 | 29.5 | 0.0  | 12.16 | 0  | N   | 2.1 | 995.4  | 76 | 8.8  |
| 2025-08-08 | 28.6 | 3.0  | 17.46 | 0  | NW  | 2.6 | 998.7  | 71 | 5.5  |
| 2025-08-09 | 28.4 | 0.0  | 18.21 | 0  | SSE | 2.7 | 1004.0 | 70 | 8.0  |
| 2025-08-10 | 26.3 | 25.5 | 4.32  | 0  | S   | 4.1 | 1002.8 | 90 | 10.0 |
| 2025-08-11 | 27.1 | 11.5 | 7.97  | 0  | S   | 5.6 | 1003.8 | 90 | 9.8  |
| 2025-08-12 | 28.2 | 1.0  | 6.88  | 0  | SSW | 4.4 | 1007.7 | 83 | 10.0 |
| 2025-08-13 | 27.9 | 0.0  | 17.21 | 0  | E   | 2.4 | 1013.5 | 76 | 9.3  |
| 2025-08-14 | 27.8 | 0.0  | 20.39 | 0  | S   | 2.6 | 1014.2 | 71 | 8.3  |
| 2025-08-15 | 28.7 | 0.0  | 24.42 | 0  | S   | 2.9 | 1011.2 | 73 | 5.0  |
| 2025-08-16 | 28.8 | 1.0  | 19.08 | 0  | S   | 3.1 | 1011.1 | 80 | 8.0  |
| 2025-08-17 | 29.8 | 0.0  | 22.79 | 0  | SSE | 3.2 | 1010.4 | 77 | 6.3  |
| 2025-08-18 | 31.0 | 0.0  | 22.43 | 0  | SSE | 2.5 | 1011.5 | 68 | 7.8  |
| 2025-08-19 | 29.9 | 0.0  | 22.92 | 0  | SE  | 2.8 | 1009.6 | 76 | 2.0  |
| 2025-08-20 | 30.4 | 0.0  | 23.70 | 0  | SSE | 2.7 | 1007.5 | 72 | 3.5  |
| 2025-08-21 | 31.3 | 0.0  | 23.14 | 0  | SSE | 2.5 | 1007.4 | 63 | 6.5  |
| 2025-08-22 | 30.3 | 0.0  | 15.55 | 0  | SSE | 2.2 | 1007.9 | 71 | 10.0 |
| 2025-08-23 | 30.4 | 0.0  | 21.77 | 0  | SSE | 2.6 | 1007.7 | 73 | 7.3  |
| 2025-08-24 | 31.3 | 0.0  | 23.05 | 0  | NE  | 2.3 | 1008.9 | 70 | 3.8  |
| 2025-08-25 | 30.6 | 0.0  | 17.21 | 0  | SSE | 2.7 | 1010.9 | 71 | 8.5  |
| 2025-08-26 | 30.1 | 0.0  | 20.41 | 0  | SSE | 3.7 | 1009.1 | 75 | 3.0  |
| 2025-08-27 | 30.7 | 0.0  | 23.07 | 0  | S   | 3.6 | 1006.1 | 67 | 3.8  |
| 2025-08-28 | 28.9 | 0.0  | 15.70 | 0  | SSE | 3.0 | 1011.0 | 63 | 6.8  |
| 2025-08-29 | 28.7 | 0.0  | 18.41 | 0  | SSE | 2.4 | 1012.1 | 76 | 6.5  |
| 2025-08-30 | 31.6 | 0.0  | 23.26 | 0  | S   | 2.5 | 1010.5 | 67 | 4.0  |
| 2025-08-31 | 30.9 | 0.0  | 21.83 | 0  | SE  | 2.7 | 1010.3 | 73 | 1.3  |

## 関連するデータの散布図



## 観測値とあてはめ値の比較




Table 2: 決定係数によるモデルの比較

|                         | モデル 1                | モデル 2                | モデル 3                | モデル 4                | モデル 5                |
|-------------------------|----------------------|----------------------|----------------------|----------------------|----------------------|
| 変数                      | 係数 (SE) <sup>†</sup> | 係数 (SE) <sup>†</sup> | 係数 (SE) <sup>†</sup> | 係数 (SE) <sup>†</sup> | 係数 (SE) <sup>†</sup> |
| 気圧                      | 0.01(0.057)          |                      | -0.04(0.037)         | -0.05(0.035)         | -0.05(0.038)         |
| 日射                      |                      | 0.22(0.034)***       | 0.22(0.034)***       | 0.15(0.043)**        | 0.21(0.047)***       |
| 湿度                      |                      |                      |                      | -0.09(0.035)*        |                      |
| 雲量                      |                      |                      |                      |                      | -0.06(0.102)         |
| R <sup>2</sup>          | 0.002                | 0.585                | 0.604                | 0.678                | 0.609                |
| Adjusted R <sup>2</sup> | -0.032               | 0.571                | 0.576                | 0.642                | 0.566                |

<sup>†</sup>\*p<0.05; \*\*p<0.01; \*\*\*p<0.001

Abbreviation: SE = 標準誤差

## 寄与率

- 決定係数 (R-squared)

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{\epsilon}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- 自由度調整済み決定係数 (adjusted R-squared)

$$\bar{R}^2 = 1 - \frac{\frac{1}{n-p-1} \sum_{i=1}^n \hat{\epsilon}_i^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2}$$

– 不偏分散で補正

## 決定係数 ( $R^2$ ・Adjusted $R^2$ ) によるモデルの比較

### F 統計量による検定

- 説明変数のうち 1 つでも役に立つか否かを検定する
  - 帰無仮説  $H_0: \beta_1 = \dots = \beta_p = 0$
  - 対立仮説  $H_1: \exists j \beta_j \neq 0$  (少なくとも 1 つは役に立つ)
- F 統計量: 決定係数 (または残差) を用いて計算

$$F = \frac{n-p-1}{p} \frac{R^2}{1-R^2}$$

- p 値: 自由度  $p, n-p-1$  の F 分布で計算

Table 3: F 統計量によるモデルの比較

| 変数             | モデル 1<br>係数 (SE) <sup>1</sup> | モデル 2<br>係数 (SE) <sup>1</sup> | モデル 3<br>係数 (SE) <sup>1</sup> | モデル 4<br>係数 (SE) <sup>1</sup> | モデル 5<br>係数 (SE) <sup>1</sup> |
|----------------|-------------------------------|-------------------------------|-------------------------------|-------------------------------|-------------------------------|
| 気圧             | 0.01(0.057)                   |                               | -0.04(0.037)                  | -0.05(0.035)                  | -0.05(0.038)                  |
| 日射             |                               | 0.22(0.034)***                | 0.22(0.034)***                | 0.15(0.043)**                 | 0.21(0.047)***                |
| 湿度             |                               |                               |                               | -0.09(0.035)*                 |                               |
| 雲量             |                               |                               |                               |                               | -0.06(0.102)                  |
| R <sup>2</sup> | 0.002                         | 0.585                         | 0.604                         | 0.678                         | 0.609                         |
| Statistic      | 0.060                         | 41.0                          | 21.4                          | 18.9                          | 14.0                          |
| p-value        | 0.8                           | <0.001                        | <0.001                        | <0.001                        | <0.001                        |

<sup>1</sup>\*p<0.05; \*\*p<0.01; \*\*\*p<0.001

Abbreviation: SE = 標準誤差

### F 統計量によるモデルの比較

#### t 統計量による検定

- 回帰係数  $\beta_j$  が回帰式に寄与するか否かを検定する
  - 帰無仮説  $H_0 : \beta_j = 0$
  - 対立仮説  $H_1 : \beta_j \neq 0$  ( $\beta_j$  は役に立つ)
- t 統計量 : 各係数ごと,  $\zeta$  は  $(X^T X)^{-1}$  の対角成分

$$t = \frac{\hat{\beta}_j}{\hat{\sigma}\zeta_j}$$

- p 値 : 自由度  $n-p-1$  の t 分布を用いて計算

#### t 統計量によるモデルの比較

#### 診断プロットによる評価

- 回帰モデルのあてはまりを視覚的に評価
  - **Residuals vs Fitted** : あてはめ値 (予測値) と残差の関係 (誤差の均一性)
  - **Normal Q-Q** : 標準化残差と標準正規分布の比較 (残差の正規性)
  - **Scale-Location** : あてはめ値と標準化残差の関係 (分散の均一性)
  - **Residuals vs Leverage** : 標準化残差とテコ比の関係 (外れ値)


Table 4: t 統計量によるモデルの比較

| 変数          | モデル 3 |       |       |                  | モデル 4 |       |       |                  | モデル 5 |       |        |                  |
|-------------|-------|-------|-------|------------------|-------|-------|-------|------------------|-------|-------|--------|------------------|
|             | 係数    | SE    | t 統計量 | p 値 <sup>1</sup> | 係数    | SE    | t 統計量 | p 値 <sup>1</sup> | 係数    | SE    | t 統計量  | p 値 <sup>1</sup> |
| (Intercept) | 69    | 37.4  | 1.83  | 0.078            | 86    | 35.1  | 2.46  | 0.021*           | 72    | 38.3  | 1.87   | 0.072            |
| 気圧          | -0.04 | 0.037 | -1.15 | 0.3              | -0.05 | 0.035 | -1.53 | 0.14             | -0.05 | 0.038 | -1.19  | 0.2              |
| 日射          | 0.22  | 0.034 | 6.53  | <0.001***        | 0.15  | 0.043 | 3.53  | 0.002**          | 0.21  | 0.047 | 4.37   | <0.001***        |
| 湿度          |       |       |       |                  | -0.09 | 0.035 | -2.49 | 0.019*           |       |       |        |                  |
| 雲量          |       |       |       |                  |       |       |       |                  | -0.06 | 0.102 | -0.577 | 0.6              |


<sup>1</sup>\*p<0.05; \*\*p<0.01; \*\*\*p<0.001

Abbreviation: SE = 標準誤差


### モデル 3 の診断プロット



## モデル 4 の診断プロット



## モデル 5 の診断プロット



## 回帰モデルによる予測

### 予測

- 新しいデータ (説明変数)  $x$  に対する **予測値**

$$\hat{y} = (1, x^T)\hat{\beta}, \quad \hat{\beta} = (X^T X)^{-1} X^T y$$

- 予測値は元データの目的変数の重み付け線形和

$$\hat{y} = w(x)^T y, \quad w(x)^T = (1, x^T)(X^T X)^{-1} X^T$$

- 重みは元データと新規データの説明変数で決定

### 予測値の性質

- 推定量は以下の性質をもつ多変量正規分布

$$\begin{aligned} \mathbb{E}[\hat{\beta}] &= \beta \\ \text{Cov}(\hat{\beta}) &= \sigma^2 (X^T X)^{-1} \end{aligned}$$

- この性質を利用して以下の3つの値の違いを評価

$$\begin{aligned} y &= (1, x^T)\beta + \epsilon && \text{(観測値)} \\ \tilde{y} &= (1, x^T)\beta && \text{(最適な予測値)} \\ \hat{y} &= (1, x^T)\hat{\beta} && \text{(回帰式による予測値)} \end{aligned}$$

- $\hat{y}$  と  $y$  は独立な正規分布に従うことに注意

## 演習

### 問題

- 誤差が平均0 分散  $\sigma^2$  の正規分布に従うとき、以下の間に答えよ
  - 予測値  $\hat{y}$  の平均を求めよ
  - 予測値  $\hat{y}$  の分散を求めよ

## 解答例

- 定義にもとづいて計算する

$$\begin{aligned}\mathbb{E}[\hat{y}] &= \mathbb{E}[(1, x^\top)\hat{\beta}] \\ &= (1, x^\top)\mathbb{E}[\hat{\beta}] \\ &= (1, x^\top)\beta \\ &= \tilde{y}\end{aligned}$$

– 真の回帰式による最適な予測値

- 定義にもとづいて計算する

$$\begin{aligned}\text{Var}(\hat{y}) &= \text{Var}((1, x^\top)(\hat{\beta} - \beta)) \\ &= (1, x^\top)\text{Cov}(\hat{\beta} - \beta)(1, x^\top)^\top \\ &= (1, x^\top)\text{Cov}(\hat{\beta})(1, x^\top)^\top \\ &= (1, x^\top)\sigma^2(X^\top X)^{-1}(1, x^\top)^\top \\ &= \sigma^2(1, x^\top)(X^\top X)^{-1}(1, x^\top)^\top\end{aligned}$$

## 信頼区間

### 最適な予測値との差

- 差の分布は以下の平均・分散をもつ正規分布に従う

$$\begin{aligned}\mathbb{E}[\tilde{y} - \hat{y}] &= (1, x^\top)\beta - (1, x^\top)\mathbb{E}[\hat{\beta}] = 0 \\ \text{Var}(\tilde{y} - \hat{y}) &= \underbrace{\sigma^2(1, x^\top)(X^\top X)^{-1}(1, x^\top)^\top}_{\hat{\beta} \text{ の推定誤差による分散}} = \sigma^2\gamma_c(x)^2\end{aligned}$$

- 標準化による表現

$$\frac{\tilde{y} - \hat{y}}{\sigma\gamma_c(x)} \sim \mathcal{N}(0, 1)$$

## 信頼区間

- 未知の分散を不偏分散で推定

$$Z = \frac{\tilde{y} - \hat{y}}{\hat{\sigma}_{\gamma_c}(x)} \sim \mathcal{T}(n-p-1) \quad (t \text{ 分布})$$

- 確率  $\alpha$  の信頼区間

$$\mathcal{J}_\alpha^c = (\hat{y} - C_\alpha \hat{\sigma}_{\gamma_c}(x), \hat{y} + C_\alpha \hat{\sigma}_{\gamma_c}(x))$$

$$P(|Z| < C_\alpha | Z \sim \mathcal{T}(n-p-1)) = \alpha$$

- 最適な予測値  $\tilde{y}$  が入ることが期待される区間

## 演習

### 問題

- 以下の問に答えなさい
  - 信頼区間について以下の式が成り立つことを示せ

$$P(\tilde{y} \in \mathcal{J}_\alpha^c) = \alpha$$

- 観測値と予測値の差  $y - \hat{y}$  の平均と分散を求めよ

### 解答例

- $C_\alpha$  の定義にもとづいて計算すればよい

$$\begin{aligned} \alpha &= P(|Z| < C_\alpha) \\ &= P\left(\left|\frac{\tilde{y} - \hat{y}}{\hat{\sigma}_{\gamma_c}(x)}\right| < C_\alpha\right) \\ &= P(|\tilde{y} - \hat{y}| < C_\alpha \hat{\sigma}_{\gamma_c}(x)) \\ &= P(-C_\alpha \hat{\sigma}_{\gamma_c}(x) < \tilde{y} - \hat{y} < C_\alpha \hat{\sigma}_{\gamma_c}(x)) \\ &= P(\hat{y} - C_\alpha \hat{\sigma}_{\gamma_c}(x) < \tilde{y} < \hat{y} + C_\alpha \hat{\sigma}_{\gamma_c}(x)) \end{aligned}$$

- 独立性を利用して計算する

$$\begin{aligned}\mathbb{E}[y - \hat{y}] &= \mathbb{E}[y] - \mathbb{E}[\hat{y}] \\ &= \tilde{y} - \tilde{y} \\ &= 0 \\ \text{Var}(y - \hat{y}) &= \text{Var}(y) + \text{Var}(\hat{y}) \\ &= \sigma^2 + \sigma^2(1, x^\top)(X^\top X)^{-1}(1, x^\top)^\top\end{aligned}$$

## 予測区間

### 観測値との差

- 差の分布は以下の平均・分散をもつ正規分布に従う

$$\begin{aligned}\mathbb{E}[y - \hat{y}] &= (1, x^\top)\beta + \mathbb{E}[\epsilon] - (1, x^\top)\mathbb{E}[\hat{\beta}] = 0 \\ \text{Var}(y - \hat{y}) &= \underbrace{\sigma^2(1, x^\top)(X^\top X)^{-1}(1, x^\top)^\top}_{\hat{\beta} \text{ の推定誤差による分散}} + \underbrace{\sigma^2}_{\text{誤差の分散}} = \sigma^2\gamma_p(x)^2\end{aligned}$$

- 標準化による表現

$$\frac{y - \hat{y}}{\sigma\gamma_p(x)} \sim \mathcal{N}(0, 1)$$

## 予測区間

- 未知の分散を不偏分散で推定

$$Z = \frac{y - \hat{y}}{\hat{\sigma}\gamma_p(x)} \sim \mathcal{T}(n-p-1) \quad (t \text{ 分布})$$

- 確率  $\alpha$  の予測区間

$$\mathcal{I}_\alpha^p = (\hat{y} - C_\alpha \hat{\sigma}\gamma_p(x), \hat{y} + C_\alpha \hat{\sigma}\gamma_p(x))$$

$$P(|Z| < C_\alpha | Z \sim \mathcal{T}(n-p-1)) = \alpha$$

- 観測値  $y$  が入ることが期待される区間
- $\gamma_p > \gamma_c$  なので信頼区間より広がる

Table 5: 推定されたモデル

| 変数          | 係数    | 標準誤差  | t 統計量 | p 値 <sup>1</sup> |
|-------------|-------|-------|-------|------------------|
| (Intercept) | 86    | 35.1  | 2.46  | 0.021*           |
| 日射          | 0.15  | 0.043 | 3.53  | 0.002**          |
| 気圧          | -0.05 | 0.035 | -1.53 | 0.14             |
| 湿度          | -0.09 | 0.035 | -2.49 | 0.019*           |

<sup>1</sup>\*p<0.05; \*\*p<0.01; \*\*\*p<0.001

## 解析の事例

### 信頼区間と予測区間


- 東京の気候データを用いて以下を試みる
  - 8月のデータで回帰式を推定する

$$\text{気温} = \text{係数} \cdot \text{気圧} + \text{係数} \cdot \text{日射} + \text{係数} \cdot \text{湿度} + \text{切片}$$


- 上記のモデルで9月のデータを予測する

### 推定されたモデル


#### 8月モデルの信頼区間




## 8 月モデルの予測区間



## 9 月の予測値の信頼区間



## 9月の予測値の予測区間



## 発展的なモデル

### 非線形性を含むモデル

- 目的変数  $y$
- 説明変数  $x_1, \dots, x_p$
- 説明変数の追加で対応可能
  - 交互作用 (交差項):  $x_i x_j$  のような説明変数の積
  - 非線形変換:  $\log(x_k)$  のような関数による変換

### カテゴリカル変数を含むモデル

- 数値ではないデータの例
  - 悪性・良性
  - 血液型 ( $A$  型,  $B$  型,  $AB$  型,  $O$  型)
- 適切な方法で数値に変換して対応
  - 2 値の場合は 1, 0 (真, 偽) を割り当てる
    - \* 悪性: 1

|                  | body      | brain  |
|------------------|-----------|--------|
| Mountain beaver  | 1.350     | 8.1    |
| Cow              | 465.000   | 423.0  |
| Grey wolf        | 36.330    | 119.5  |
| Goat             | 27.660    | 115.0  |
| Guinea pig       | 1.040     | 5.5    |
| Dipliodocus      | 11700.000 | 50.0   |
| Asian elephant   | 2547.000  | 4603.0 |
| Donkey           | 187.100   | 419.0  |
| Horse            | 521.000   | 655.0  |
| Potar monkey     | 10.000    | 115.0  |
| Cat              | 3.300     | 25.6   |
| Giraffe          | 529.000   | 680.0  |
| Gorilla          | 207.000   | 406.0  |
| Human            | 62.000    | 1320.0 |
| African elephant | 6654.000  | 5712.0 |
| Triceratops      | 9400.000  | 70.0   |
| Rhesus monkey    | 6.800     | 179.0  |
| Kangaroo         | 35.000    | 56.0   |
| Golden hamster   | 0.120     | 1.0    |
| Mouse            | 0.023     | 0.4    |
| Rabbit           | 2.500     | 12.1   |
| Sheep            | 55.500    | 175.0  |
| Jaguar           | 100.000   | 157.0  |
| Chimpanzee       | 52.160    | 440.0  |
| Rat              | 0.280     | 1.9    |
| Brachiosaurus    | 87000.000 | 154.5  |
| Mole             | 0.122     | 3.0    |
| Pig              | 192.000   | 180.0  |

- \* 良性 : 0
- 3 値以上の場合は **ダミー変数** を利用する (カテゴリ数-1 個)
  - \* A 型 : (1,0,0)
  - \* B 型 : (0,1,0)
  - \* O 型 : (0,0,1)
  - \* AB 型 : (0,0,0)


## 解析の事例

### 非線形変換による線形化


- 様々な動物の体重と脳の重さの関係を調べる
  - 体重は 5 桁程度のばらつき
  - 脳の重さは 4 桁程度のばらつき
- 以下の変換を検討する
  - 変換なし

- 体重を対数変換
- 体重および脳の重さを対数変換


### 散布図 (変換なし)




## 散布図 (体重を対数変換)




## 散布図 (体重と脳の重さを対数変換)



### 単回帰 (回帰直線と信頼区間)




### 単回帰 (外れ値を除いた回帰直線と信頼区間)



## 非線形な関係の分析

- 東京の気候データ (9 月) を用いて 気温に影響する変数の関係を検討する
  - 日射と気圧の線形回帰モデル  
(日射と気圧が気温にどのように影響するか検討する)
  - これらの交互作用を加えた線形回帰モデル  
(日射と気圧の相互の関係の影響を検討する)

## 関連データの散布図



## 交互作用の効果

- 気温への寄与
  - 線形モデル
    - 日射の係数は正
    - 気圧の係数は負
  - 交互作用を加えたモデル
    - 日射の係数は気圧がある値より高い場合に負
    - 気圧の係数は日射がある値より高い場合に負
    - 係数の有意性は低いのでより多くのデータでの分析が必要

Table 6: 交互作用の効果

| 変数                      | 交互作用なし               | 交互作用あり               |
|-------------------------|----------------------|----------------------|
|                         | 係数 (SE) <sup>1</sup> | 係数 (SE) <sup>1</sup> |
| 日射                      | 0.14(0.064)*         | 34(15.7)*            |
| 気圧                      | -0.38(0.075)***      | 0.12(0.239)          |
| 日射 * 気圧                 |                      | -0.03(0.016)*        |
| R <sup>2</sup>          | 0.529                | 0.602                |
| Adjusted R <sup>2</sup> | 0.495                | 0.556                |
| F 統計量                   | 15.2                 | 13.1                 |
| p 値                     | <0.001               | <0.001               |


<sup>1</sup>\*p<0.05; \*\*p<0.01; \*\*\*p<0.001

Abbreviation: SE = 標準誤差

## カテゴリカル変数の利用

- 東京の気候データを用いて 気温を回帰するモデルを検討する
  - 降水の有無を表すカテゴリカル変数を用いたモデル  
(雨が降ると気温が変化することを検証する)
  - 月をカテゴリカル変数として加えたモデル  
(月毎の気温の差を考慮する)

## 関連データの散布図



## カテゴリカル変数の効果

- 気温への寄与
  - 雨の 有無モデル
    - \* 経験的に雨の有無は気温と無関係ではないと考えられる
    - \* 決定係数から回帰式としての説明力は極めて低い
    - \* 通年では雨と気温の関係は積極的に支持されない
  - 雨の有無+月モデル
    - \* 月毎の気温の偏りが月の係数として推定される
    - \* 雨の日の方が気温が低いことが支持される


Table 7: カテゴリカル変数の効果

| 変数                      | 雨の有無                 | 雨の有無+月               |
|-------------------------|----------------------|----------------------|
|                         | 係数 (SE) <sup>I</sup> | 係数 (SE) <sup>I</sup> |
| 雨の有無                    |                      |                      |
| FALSE                   | —                    | —                    |
| TRUE                    | 0.23(1.01)           | -2.1(0.323)***       |
| 月                       |                      |                      |
| 1                       |                      | —                    |
| 2                       |                      | -0.26(0.689)         |
| 3                       |                      | 4.6(0.676)***        |
| 4                       |                      | 9.6(0.682)***        |
| 5                       |                      | 13(0.680)***         |
| 6                       |                      | 19(0.683)***         |
| 7                       |                      | 22(0.671)***         |
| 8                       |                      | 23(0.672)***         |
| 9                       |                      | 20(0.682)***         |
| 10                      |                      | 12(0.677)***         |
| 11                      |                      | 6.3(0.677)***        |
| 12                      |                      | 2.0(0.672)**         |
| (Intercept)             | 17(0.529)***         | 6.8(0.475)***        |
| R <sup>2</sup>          | 0.000                | 0.909                |
| Adjusted R <sup>2</sup> | -0.003               | 0.906                |
| F 統計量                   | 0.054                | 292                  |
| p 値                     | 0.8                  | <0.001               |

<sup>I</sup>\*p<0.05; \*\*p<0.01; \*\*\*p<0.001

Abbreviation: SE = 標準誤差

## 実測値とあてはめ値の関係



## 次回の予定

- 第1回: 主成分分析の考え方
- 第2回: 分析の評価と視覚化